



自适应人机交互协作：用于医学报告生成的强化学习驱动视觉语言模型

曹一鸣

Alibaba-NTU Global e-Sustainability CorpLab (ANGEL) 南洋

理工大学

新加坡，新加坡

yiming.cao@ntu.edu.sg

崔丽珍 中国济南

软件学院

clz@sdu.edu.cn

李真

中国济南，山东大学齐鲁医院

qilulizhen@sdu.edu.cn

苗春艳

南洋理工大学-加拿大皇家学院老年人积极生活联合卓越研究中

心 (LILY)

新加坡南洋理工大学 ascymiao@ntu.edu.sg

摘要

大型语言模型 (LLM) 和视觉模型在医疗保健领域展现出巨大的潜力。视觉语言模型 (VLMs) 的集成在自动生成医疗报告方面取得了重大进展。然而，在临床实践中，如何有效地将医生的反馈纳入报告生成过程仍是一个尚未解决的难题。在本文中，我们提出了一种自适应的人类-LLMs 协同视觉语言模型，它能根据医生和 LLMs 的反馈动态调整报告生成过程。我们设计了一个强化学习模块，根据医生的反馈动态更新由 VLM 生成的生成内容，从而解决了将医生反馈整合到生成模型中的难题。为了减轻对医生反馈的过度依赖，我们引入了 RL-LLM 模块，该模块使用 LLM 来评估生成报告的质量。该模型采用与临床医生合作的参与式设计方法，以提高报告的准确性和临床可用性。

中央监控系统概念

• 以人为中心的计算 → 人机交互 (HCI); - 应用计算 → 健康信息学。

关键词

人机交互、医疗报告生成、健康信息学

ACM 参考格式:

曹一鸣、李真、崔丽珍、苗春燕。2025.自适应人机交互协作：用于医学报告生成的强化学习驱动视觉语言模型。In *Extended Abstracts of the CHI Conference on Human Factors in Computing Systems (CHI EA '25)*, April 26-May 01, 2025, Yokohama, Japan. ACM, New York, NY, USA, 6 pages. <https://doi.org/10.1145/3706599.3719852>

1 引言

医疗成像技术的日益普及极大地提高了医疗诊断能力。然而，根据这些图像生成医疗报告的过程仍然是一项劳动密集型且容易出错的工作。尽管医疗图像分析自动化系统取得了进步，但自动生成医疗报告仍然充满挑战，包括对医疗图像中关键病变、异常其他重要发现的描述不完整或不准确。依靠人类的专业知识来创建高质量的报告是不可或缺的，但却限制了其可扩展性和效率。因此，探索结合人工智能 (AI) 和人类专业知识优势的方法以优化医疗报告生成至关重要。

本文探讨了通过人工智能协作改进医疗报告生成所必需的两个关键研究问题 (RQs)。第一个研究问题是：如何将专业医生的反馈意见有效整合到报告生成流程中，以提高报告质量？医疗专业人员的反馈对于提高生成报告的准确性和完整性至关重要。医生拥有的领域专业知识对于验证人工智能模型生成的内容不可或缺，尤其是在涉及医疗报告的关键和细微之处时。然而，挑战在于如何在不引入过多人工干预或降低自动化效率的情况下将这些反馈有效地纳入模型。第二个研究问题是，如何确保模型根据医生的反馈动态调整生成的内容，同时又不过分依赖医生，从而降低自动化程度？这个问题涉及自动化和人工干预之间的平衡。虽然医生的意见对于完善人工智能生成的报告是必要的、

允许为个人或课堂用途免费复制本作品的全部或部分内容的电子版或硬拷贝，但不得以营利或商业利益为目的制作或分发副本，且副本须标明本声明和完整的引文。必须尊重本作品中第三方内容的版权。如需其他用途，请联系所有者/作者。

CHI EA '25, 日本横浜

©2025 版权归所有者/作者所有。美国计算机学会 ISBN

979-8-4007-1395-8/25/04

<https://doi.org/10.1145/3706599.3719852>

过度依赖人工纠正可能会抵消自动化带来的好处。关键是要设计出能够从反馈中学习并不断改进的系统,从而减少对持续人工输入的需求。为了应对这些挑战,我们提出了一种自适应的人机 LLM 协同视觉语言模型,该模型将医生的反馈整合到报告生成过程中,并逐步优化其输出。该模型的主要目标是创建一个主动的、临床医生在环路中工具,它不仅能自动生成报告,还能从临床医生的反馈中学习,从而不断改进其输出。该模型由三个主要模块组成:生成模块,采用多模态视觉语言模型从图像中生成医疗报告初稿;强化学习模块,从医生的修改中学习并相应调整报告生成过程;大型语言模型提炼,使用 LLM 对生成的报告进行自动评估和改进,最大限度地减少对人工输入的依赖。具体来说,生成模块采用了一个视觉语言模型,该模型可对医学图像进行编码,并通过基于转换器的架构生成文本描述。该模型通过注意力机制整合图像特征和文本上下文,使其能够专注于图像的相关区域,从而获得更准确的描述。这种方法通常用于图像字幕,使模型能够直接从医学图像中生成与医学相关的文本内容,然后对其进行迭代再编辑。强化学习模块解决了动态模型调整的问题。通过将医生反馈作为奖励信号,系统不断提高生成高质量报告的能力。医生会提出纠正意见或建议,而模型会根据这些互动优化其报告策略。经过训练,奖励模型会将积极反馈与成功的报告修改联系起来,从而引导系统提高性能。大型语言模型提炼模块(RL-LLM)是减少人工干预的一种新方法。该系统使用预先训练好的 LLM 来评估生成报告的质量并提供奖励信号,而不是人工标注反馈或训练奖励模型。这种方法简化了流程,通过利用大型语言工具的强大功能,使流程具有可扩展性并更加高效。

评估文本质量的模型。

本文概述了这些模块的设计和实施,讨论了它们在自适应系统中的整合,该系统可从反馈中学习,同时保持高度自动化。自适应人类-LLMs 协作框架既能提高医疗报告的准确性,又能提高报告生成过程的效率,最终使医疗服务提供者和患者都能从中受益。

2 相关工作

2.1 医疗保健领域的多模态大型模型

在医疗保健领域整合多模态大型模型,通过结合临床文本、医学图像和传感器数据等不同数据类型来改进决策,从而推进了人工智能支持医疗实践的方式。然而,在临床环境中部署这些模型也面临着与偏差、监管合规性和对人工智能结果的信任有关的挑战。

GPT-3 和 GPT-4 等基础模型被认为是医疗保健领域的变革性模型,可整合各学科的知识并执行从临床问题解答到报告总结等一系列任务。然而,这些模型在医疗环境中存在透明度、偏差和输出准确性方面的风险[2], [18]。尽管存在这些挑战,LLMs 在医学问题解答方面仍大有可为,其性能接近专家水平 [19], [20]。

医学成像中的多模态模型对自动生成报告特别有用。Hyland 等人推出了 MAIRA-1,它结合了医学图像和文本,用于生成上下文感知的放射学报告[9]。Lecler 等人进一步证明了基于 GPT 的模型通过合并图像识别和 NLP 提高诊断准确性的潜力[12]。Xu 等人提出了 ELIXR 系统,该系统将 LLM 与放射学视觉编码器相结合,用于 X 射线分析,扩大了 LLM 在医学成像中的应用[21]。

在生物医学知识提取方面,Gu 等人展示了 LLM 如何从医学文献中提炼知识,以识别药物不良事件等风险[8];Preston 等人展示了深度学习如何构建肿瘤学数据,以提取有价值的特定患者见解[16]。虽然这些进展前景广阔,但监管和信任问题仍然是在医疗保健领域有效整合多模态模型的关键。Gilbert 等人建议,必须将 LLMs 作为医疗设备对待,并进行严格的监管审查[6]。这些监管问题对于确保人工智能在医疗保健领域的安全性和有效性至关重要。

人工智能模型的可解释性仍然是一个重大挑战。Nori 等人强调,尽管 GPT-4 等模型取得了成功,但仍需解决训练数据偏差和决策透明度等问题[13]。此外,模型需要解释其推理过程,这对确保临床医生的信任至关重要,尤其是在高风险的医疗场景中[14]。

尽管存在这些挑战,多模态模型在为临床医生和患者简化医疗信息方面已显示出潜力。Jeblick 等人展示了如何利用 ChatGPT 来简化放射学报告,使其在不损失诊断准确性的前提下更加方便患者[10]。Krishna 等人开发了自动生成 SOAP 笔记的技术,有助于减轻临床医生的管理负担[11]。

总之,虽然多模态大型模型在医疗保健领域大有可为,但要将其有效应用于临床环境,克服透明度、偏差和合规性等挑战至关重要。

2.2 人类与人工智能在医疗保健领域的合作

人类与人工智能的合作已成为医疗保健领域的一个关键领域,旨在增强临床医生的决策能力并改善患者的治疗效果。要成功整合人工智能,就必须设计出符合临床医生需求、使用直观、操作透明的系统。

以用户为中心的设计对于在医疗保健领域采用人工智能至关重要。Cai 等人强调,人工智能系统必须通过提供用户友好的界面和清晰的沟通来迎合医疗专业人员的需求,从而确保在高压环境下的信任和有效使用[4], [3]。他们的工作强调了

设计人工智能工具, 帮助临床医生管理人工智能的不确定性和不完善性, 尤其是在复杂的医疗决策场景中。

人工智能在解决医疗决策中的认知偏差方面的作用是另一个关键的研究领域。巴赫等人的研究表明, 人工智能可以通过提出替代诊断或强调被忽视的信息, 帮助减少眼科中的锚定偏差[1]。这一概念适用于各种医疗领域, 表明人工智能可以提高诊断准确性, 减少患者护理中的错误。

确保人工智能系统的公平性和透明度也至关重要。Chien 等人讨论了临床试验中多学科公平性考虑的重要性, 以减少数据和算法中的偏差[5]。人工智能系统的设计必须避免强化现有差距, 确保公平和问责。

成功整合人工智能还需要了解医疗保健的社会技术动态。Procter 等人和 Zajac 等人强调, 人工智能系统必须值得信赖, 并能适应多样化和复杂的医疗环境[17]、[22]。人工智能系统必须无缝集成到临床医生的工作流程中, 确保它们能增强而不是破坏现有的实践。Gu 等人介绍了 XPath, 这是一个旨在为病理学家提供支持的系统, 它强调了工作流程整合在人工智能应用中的重要性[7]。

在人工智能部署过程中, 监管和伦理方面的挑战至关重要。Petersen 等人探讨了人工智能系统遵守医疗法规的必要性, 以确保患者安全、隐私和遵守医疗标准[15]。

总之, 要想在医疗保健领域实现人类与人工智能的成功合作, 就必须在设计人工智能系统时考虑到临床医生, 提高透明度, 并将其无缝集成到临床工作流程中。通过解决认知偏差、公平性和合规性等问题, 人工智能可以有效增强临床医生的决策能力, 改善患者护理效果。随着人工智能的不断发展, 它将在医疗服务变革中发挥越来越关键的作用。

3 方法

医学影像报告的自动生成本身就具有不确定性, 容易忽略对某些关键病变或区域的描述。我们提出了两个研究问题: **问题 1:** 如何将专业医生的反馈有效整合到报告生成过程中, 以提高报告质量? **问题 2:** 如何确保模型能根据医生的反馈动态调整生成的内容, 避免过度依赖医生, 从而降低自动化程度?

在本节中, 针对上述问题, 我们将介绍一种自适应人机协作视觉语言模型, 它可以根据医生的反馈调整报告内容, 并通过这些反馈逐步优化报告生成过程。

3.1 框架概述

图 1 所示的自适应人类-LLMs 视觉-语言协作模型由三个主要模块组成, 它们共同作用以提高模型在报告生成方面的性能

质量。首先, 生成模块利用多模态视觉语言模型生成报告草稿。其次, 我们设计了一个强化学习模块, 根据医生修改的内容和反馈优化生成过程和模型参数。第三, 我们开发了一个大型语言分解模块, 利用大型语言模型来学习医生的反馈, 并自适应地调整生成的内容。接下来, 我们将详细介绍这三个关键模块。

3.2 发电模块

我们系统中的生成模块利用视觉语言模型, 根据给定的医学图像生成文本医学报告。该架构采用基于变换器的设计, 这是一种广泛用于图像字幕和文本生成任务的方法。该模块由三个主要组件组成: 图像编码器、交互组件和语言解码器。

第一步是对输入的医学图像进行编码, 以提取有意义的特征。图像编码器通常采用卷积神经网络 (CNN) 或视觉变换器 (ViT), 这两种技术都能有效处理图像数据。CNN 或 ViT 架构用于捕捉图像中的分层特征。

医疗图像的特征。将输入的医学图像表示为 I 图像编码器的输出表示为 F_{ie} , 它代表了图像的特征图:

$$F_{ie} = \text{编码器}(I), \quad (1)$$

就 CNN 而言, 这一编码过程涉及多个对话层, 这些对话层按不同的抽象程度逐步提取特征。对于 ViT, 输入图像被分割成固定大小的斑块, 然后通过一系列转换层进行线性嵌入和处理。

交互组件的设计目的是对图像特征和文本特征进行调整和整合, 使模型能够关注图像中与生成文本最相关的特定区域。关键的思路是利用注意力机制在图像区域和相应的文本描述之间建立联系。在我们的方案中, 多头注意力机制使解码器能够根据当前部分生成文本的上下文, 关注图像中与生成报告中下一个单词相关的区域。这种互动使模型能够学习图像区域与相应文本描述之间的空间关系。

语言解码器负责生成医学影像报告的最终文本输出。解码器采用标准的 Transformer 架构, 将来自图像编码器和注意力模块的融合特征作为输入。它以自回归方式生成文本, 根据当前输入 (包括图像特征和之前生成的) 预测下一个单词。从形式上, 解码过程的模型如下

$$p(w_t | w_{1:t-1}, F_{ie}) = \text{解码器}(w_{1:t-1}, F_{ie}) \quad (2)$$

其中 w_t 表示在时间步骤 t 时预测的单词, $w_{1:t-1}$ 是之前生成的文本。

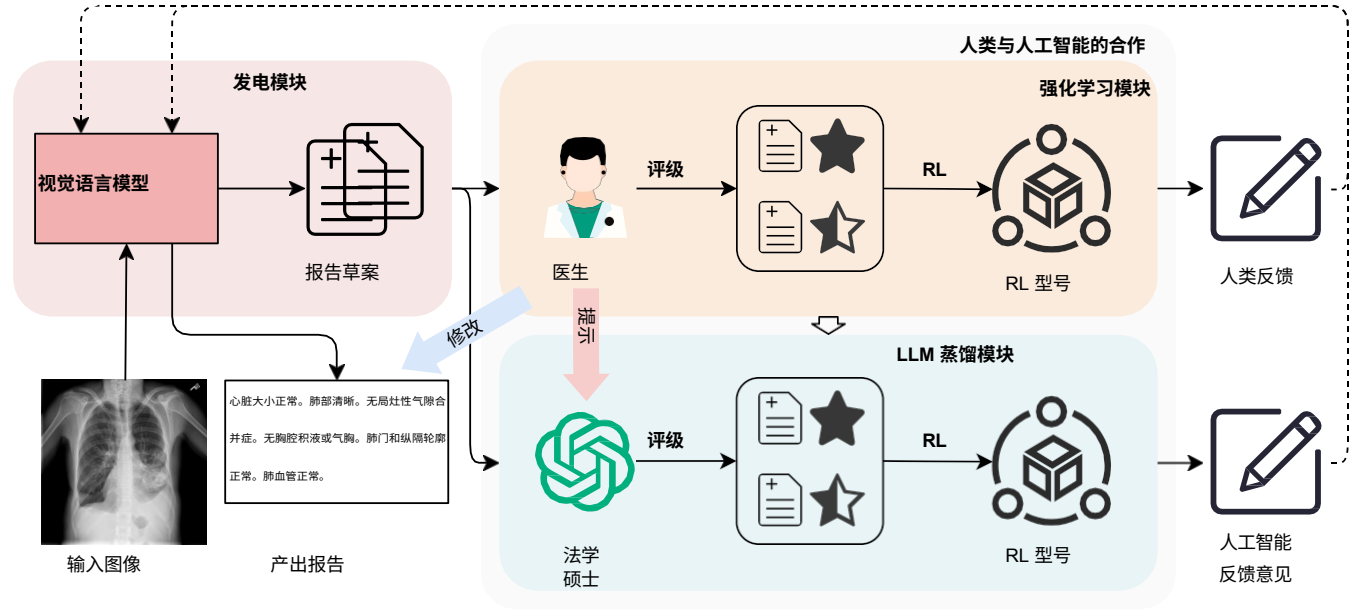


图 1: 自适应人类-LLMs 多模态视觉-语言协作模型示意图

3.3 强化学习模块

在强化学习模块中, 医疗专业人员首先通过人工反馈优化生成模块生成的报告草稿。然后, 应用强化学习从医生的修改中学习, 优化报告生成过程。在这一设置中, 状态空间由医生的修改或选择操作组成, 可视作系统的状态。每次调整或选择都代表一种状态, 描述了报告中已生成内容与医生意图之间的差异。行动空间代表模型的“行动”, 即根据医生的修改或新报告内容的生成进行的调整。奖励信号基于医生的反馈: 如果医生接受修改并认为内容准确, 系统就会获得正奖励。反之, 如果报告不符合医生的需求或包含错误, 系统就会获得负奖励。最后, 强化学习中的策略梯度法被用于策略优化, 确保模型在每一轮交互后都能根据医生的反馈学习到最优生成策略。可行的方案如下

给定图像输入 i_x , 生成模块输出两份报告草稿, 即 r_1 和 $r_{(2)}$ 。医生手动处理输入和报告草稿, 并根据准确性标准进行评分、医疗报告中的一致性和合理性。反馈以三元组 (i_x, r_b, r_w) 的形式进行注释, 其中 r_b 和 r_w 分别代表更受欢迎和不太受欢迎的回复。通过最小化损失函数 L 来训练奖励模型。

$$L(\phi) = -E_{(i_x, r_b, r_w)} [\log \sigma r_{\phi}(i_x, r_b) - r_{\phi}(i_x, r_w)] \quad (3)$$

其中, σ 表示 sigmoid 函数。随后, 通过强化学习进行优化, 使奖励最大化

奖励模型给出的, 它是人类偏好的替代物。

3.4 大型视觉语言模型蒸馏模块

为了解决因过度依赖医生而导致模型自动化程度降低的难题, 我们提出了一种将强化学习 (RL) 与大型语言模型 (LLM) 反馈相结合的新方法, 称为 RL-LLM。这种方法利用大型语言模型的强大功能来评估生成报告草稿的质量, 并将 LLM 的评估结果作为强化学习过程中的奖励信号, 从而省去了劳动密集型的人工偏好注释和奖励模型训练。

在传统的强化学习中, 代理会根据自己的行动接收奖励信号, 并以此调整策略, 提高未来表现。在我们提出的 RL-LLM 框架中, 我们不依赖明确的人类反馈或手工创建的再监护模型, 而是使用预先训练好的大型语言模型提供的反馈作为奖励信号。这使得强化学习过程可以直接从 LLM 对生成内容的评估中启动, 从而大大减少了训练通常所需的时间和资源。

让 s_t 代表 t 时间的状态, 它对应于系统生成的报告草稿。行动 a_t 是每一步对报告所做的修改或调整。从状态到下一状态的转换由操作 a_t 决定, 而奖励则来自 LLM 对报告的评估。奖励通过 LLM 生成的报告, 可以计算出每个时间步的信号质量。LLM 得出的质量分数反映了




图 2：医生体验评估中医生对报告生成质量的反馈图示

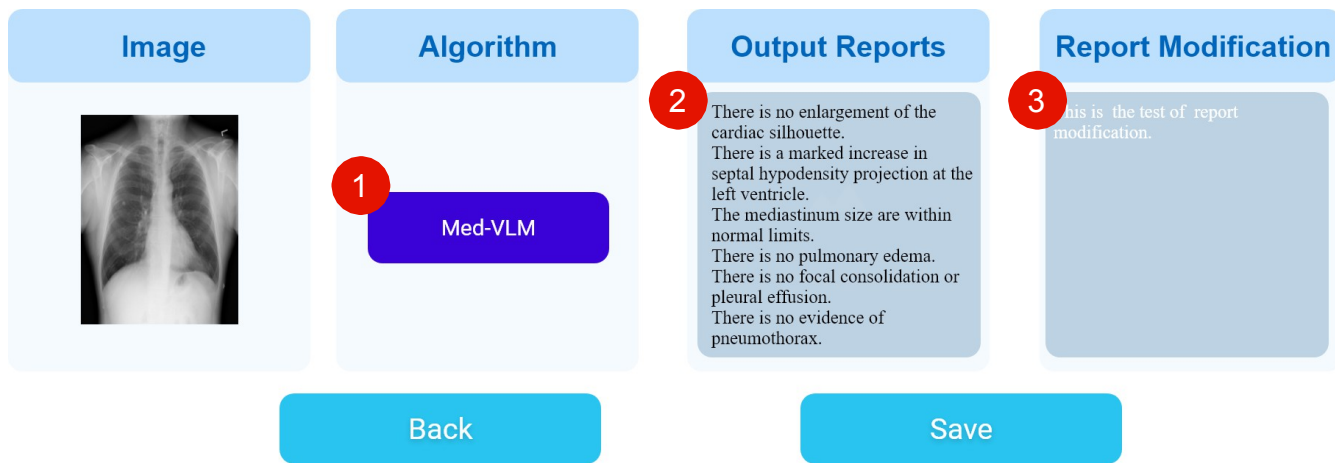


图 3：医生体验评估中医生对报告生成质量的反馈场景系统。（1）医疗视觉语言模型，（2）输出报告，（3）医生对生成报告的反馈区域

报告的感知质量。这个分数作为强化学习代理的奖励。

RL-LLM 方法的主要优势在于，它省去了传统强化学习设置中通常需要的人工偏好注释和奖励模型训练。在传统的强化学习系统中，人类注释者必须手动对生成的报告提供反馈，并且必须训练一个单独的奖励模型来预测这些反馈。这一过程不仅耗时，而且容易出现不一致和偏差。相比之下，RL-LLM 直接使用 LLM 对生成内容质量的评估作为奖励信号，从而简化了学习过程，使其更具可扩展性。预先在大量数据上训练过的大型语言模型能够以一种既能反映语言连贯性又能反映医疗准确性的方式来评估生成报告的质量，从而确保报告的高质量，而不需要在每次迭代中都明确地由人工输入。

3.5 模型评估

为了科学地评估自适应人机协作多模态视觉语言模型的有效性，我们对该模型进行了详细的

可以从报告质量和医生经验等方面进行分析。

报告质量评估是评价模型有效性的核心指标。常用的方法包括使用 BLEU、ROUGE 和 CIDEr 等自然语言处理评估指标，评估生成报告的准确性、术语一致性和逻辑连贯性。此外，报告完整性评估对于检查生成的报告是否涵盖了医学影像中需要描述的所有关键区域和信息也至关重要。

医生体验评估是该模型实际应用中的一个重要评价指标，旨在确定该模型是否能提高医生的工作效率，减少他们的工作量。主要方法包括评估交互性、响应速度以及医生的满意度和接受度。交互性和响应速度用于评估医生与系统之间的交互效率，重点是系统的响应时间和医生输入后的实时反馈能力。通过调查或访谈收集医生的满意度和接受度，收集对报告生成质量、系统可用性和个性化适应性的反馈，评估医生对该模型的接受度和信任度。

图 2 展示了医生评估视觉语言模型生成的报告质量的方法。一旦模型生成了报告草稿, 医生就会对报告内容进行审核和修改, 以纠正任何不准确之处并澄清含糊不清的陈述。修改后的报告将与生成报告的原始医学影像结合在一起。修改后的报告和相关的医学影像组合成一个反馈样本, 作为系统的高质量训练示例。通过将这些反馈纳入模型的训练过程, 系统能够从医生的修正和调整中学习, 从而提高自己的能力, 在未来生成更准确、更符合实际情况的报告。医生与模型合作的迭代过程使模型能够通过不断学习专家的意见, 随着时间的推移而逐步完善。每一个新的反馈样本都来自与医疗专业人员的真实互动, 使模型能够调整其对如何解读医学影像的理解, 并生成更符合临床预期的相应报告。图 3 展示了这种评估方法的系统实施。

4 结论

本文介绍了一种自适应的人类-LLMs 协作框架, 通过将专业医生的反馈整合到人工智能驱动的流程中来改进医疗报告的生成。通过所提出的多模态视觉语言模型, 我们解决了该领域的两个核心难题: 一是通过整合专家反馈来提高报告质量, 二是确保模型能够动态调整其内容, 而无需过多的人工干预。该框架包含三个关键模块--生成、强化学习模块和大型语言模型提炼模块, 以实现自动化和人类专业知识之间的平衡。通过利用人工智能在图像分析方面的优势和医学专业人员的丰富经验, 我们的方法旨在显著提高医疗报告生成的准确性、完整性和效率。所提出的模型不仅能减轻医疗服务提供者的负担, 还能确保人工智能驱动模型随着时间推移不断学习和改进, 从而最大限度地减少对持续人工输入的需求。这种动态适应性有望提高自动医疗报告生成模型的可扩展性, 提供一种能满足医疗保健行业日益增长的需求解决方案。未来的工作重点是进一步优化这些模块, 并探索它们在实际临床环境中的适用性, 最终努力通过人工智能驱动的进步提供更好的医疗成果。

致谢

本研究部分由阿里巴巴集团和新加坡南洋理工大学通过阿里巴巴-南洋理工大学全球电子可持续发展实验室 (AN- GEL) 以及中国自然科学基金 (92367202) 支持。

参考资料

[1] Anne Kathrine Petersen Bach, Trine Munch Nørgaard, Jens Christian Brok 和 Niels van Berkel. 2023."如果我有的是时间": 眼科医生对减轻临床人工智能支持锚定偏差的看法》。In *Proceedings of the 2023 CHI Conference on Human Factors in Computing Systems, CHI 2023, Hamburg, Germany, April 23-28, 2023*. ACM, 16:1-16:14.

[2] Rishi Bommasani, Drew A Hudson, Ehsan Adeli, Russ Altman, Simran Arora, Sydney von Arx, Michael S Bernstein, Jeannette Bohg, Antoine Bosselut 和

Emma Brunskill et al. 论基础模型的机遇与风险。 *arXiv preprint arXiv:2108.07258* (2021).

[3] Carrie J Cai, Emily Reif, Narayan Hegde, Jason Hipp, Been Kim, Daniel Smilkov, Martin Wattenberg, Fernanda Viegas, Greg S Corrado, and Martin C Stumpe et al. 医疗决策过程中应对不完善算法的人本工具。 In *Proceedings of the 2019 CHI Conference on Human Factors in Computing Systems*.1-14.

[4] Carrie J Cai, Samantha Winter, David Steiner, Lauren Wilcox 和 Michael Terry. 2019."你好, 人工智能": 揭示医疗从业者对人机协作决策的入职需求。 *Proceedings of the ACM on Human- Computer Interaction* 3, CSCW (2019), 1-24.

[5] Isabel Chien, Nina Deliu, Richard Turner, Adrian Weller, Sofa Villar, and Niki Kilbertus.2022. 临床试验机器学习中的多学科公平性考虑。 *Accountability, and Transparency*.906-924.

[6] Stephen Gilbert, Hugh Harvey, Tom Melvin, Erik Vollebregt 和 Paul Wicks. 2023. 大型语言模型人工智能聊天机器人需要作为医疗设备获得批准。 *自然医学* 29, 10 (2023), 2396-2398。

[7] 顾红艳、梁源、徐一帆、克里斯托弗·卡祖-威廉姆斯、Shino Magaki、Negar Khanlou、Harry Vinters、陈泽生、倪硕、杨春旭等 2023. 利用 XPath 改进工作流集成: 病理学领域人机交互诊断系统的设计与评估》。 *ACM Transactions on Computer-Human Interaction* 30, 2 (2023), 1-37.

[8] Yu Gu, Sheng Zhang, Naoto Usuyama, Yonas Woldesenbet, Clif Wong, Praneeth Sanapathi, Mu Wei, Naveen Valluri, Erika Strandberg 和 Tristan Naumann 等, 2023 年。 为生物医学知识提取提炼大型语言模型: *arXiv preprint arXiv:2307.06439* (2023).

[9] Stephanie Hyland, Shruthi Bannur, Kenza Bouzid, Daniel C Castro, Mercy Ranjit, Anton , and Fernando Pérez-García et al. MAIRA-1: A specialised large multimodal model for radiology report generation. *arXiv preprint arXiv:2311.13668* (2023).

[10] Katharina Jeblick、Balthasar Schachtner、Jakob Dextl、Andreas Mittermeier、Anna Theresa St er、Johanna Topalis、Tobias Weber、Philipp Wesp、Bastian Sabel 和 Jens Ricke 等, 2022 年。 ChatGPT 让药物易于下咽: 关于简化放射学报告的探索性 案例研究 。 *arXiv preprint arXiv:2212.14882* (2022)。

[11] Kundan Krishna, Sopan Khosla, Jeffrey P Bigham, and Zachary C Lipton.2020.使用模块化和marization 技术从医患对话中生成 SOAP 笔记。 *arXiv 预印本 arXiv:2005.01795* (2020).

[12] Augustin Lecler, Loïc Duron, and Philippe Soyer.2023. 基于 GPT 模型的放射学革命: 目前的应用、未来的可能性和局限性 of ChatGPT. *诊断与介入成像* 104, 6 (2023), 269-274。

[13] Harsha Nori, Nicholas King, Scott Mayer McKinney, Dean Carignan 和 Eric Horvitz. 2023.GPT-4在医学挑战问题上的能力。 *arXiv preprint arXiv:2303.13375* (2023).

[14] Namkee Oh, Gyu-Seong Choi, and Woo Yong Lee.2023.ChatGPT 进入手术室: 评估 GPT-4 的性能及其在大型语言模型时代外科教育和培训中的潜力。 *外科 治疗与研究年鉴* 104, 5 (2023), 269。

[15] Eike Petersen, Yannik Potdevin、Esfandiar Mohammadi、Stephan Zidowitz、Sab- rina Breyer、Dirk Nowotka、Sandra Henn、Ludwig Pechmann、Martin Leucker 和 Philipp Rostalski 等人, 2022 年。符合责任和监管要求的医学机器学习: 挑战与解决方案调查 。 *IEEE Access* 10 (2022), 58375-58418。

[16] Sam Preston, Mu Wei, Rajesh Rao, Robert Tinn, Naoto Usuyama, Michael Lucas, Yu Gu、Roshanthi Weerasinghe、Soohee Lee 和 Brian Piening 等, 2023 年。实现真实世界数据的结构化: 深度学习从临床文本中提取肿瘤信息, 并提供患者级别的监督。 *Patterns* 4, 4 (2023), 1-14。

[17] Rob Procter, Peter Tolmie 和 Mark Rouncefield. 2023. 让人工智能承担责任: 在医疗保健领域提供值得信赖的人工智能所面临的挑战》。 *ACM Transactions on Computer-Human Interaction* 30, 2 (2023), 1-34.

[18] 默里·沙纳汉2022. 谈论大型语言模型》。 *ArXiv 预印本 arXiv:2212.03551* (2022).

[19] Karan Singhal、Shekoofeh Azizi、Tao Tu、Sara Mahdavi、Jason Wei、Hyung Won Chung、Nathan Scales、Ajay Tanwani、Heather Cole-Lewis、Stephen Pfohl 等 al. 2023. 大型语言模型编码临床知识。 *自然* (2023 年), 1-9。

[20] Karan Singhal、Tao Tu、Juraj Gottweis、Rory Sayres、Ellery Wulczyn、Le Hou、Kevin Clark、Stephen Pfohl、Heather Cole-Lewis、Darlene Neal 等人, 2023. 利用大型语言模型实现专家级医学问题解答。 *arXiv preprint arXiv:2305.09617* (2023).

[21] Shawn Xu, Lin Yang, Christopher Kelly, Marcin Sieniek, Timo Kohlberger, Martin Ma, Wei-Hung Weng, Attila Kiraly, Sahar Kazemzadeh, and Zakkai Melamed et al. ELIXR: Towards a general purpose X-ray artificial intelligence system through alignment of large language models and radiology vision encoders. *arXiv preprint arXiv:2308.01317* (2023), 1-52.

[22] Hubert D Zajac, Dana Li, Xiang Dai, Jonathan F Carlsen, Finn Kensing, and Tariq O Andersen.2023.面向临床医生的野生人工智能: 盘点人机交互的社会技术挑战与机遇》。 *ACM Transactions on Computer-Human Interaction* 30, 2 (2023), 1-39.